Table des matières

Introduction **2**

Modèle de base **2**
Méthodologie 2
Modèle linéaire généralisé 3

Ajustement des modèles **4**
Modèle linéaire généralisé avec une régularisation 4
Modèle des k plus proches voisins 5
Arbre de décision 6
Ensemble d'arbres de décision agrégés par *bagging* 8
Forêt aléatoire 8
Modèle de gradient *boosting* 9

Comparaison des modèles **10**
Courbe ROC et aire sous la courbe 12
F-mesure 13
Sensibilité 14
Temps d'entrainement 14
Choix des meilleurs modèles 15

Interprétation des deux meilleurs modèles **15**
Modèle de gradient *boosting* 15
Avantages et désavantages du modèle 16
Modèle avec régularisation Lasso 17
Avantages et désavantages du modèle 18

Conclusion **18**

Bibliographie **19**

Introduction

Le but de l'analyse présentée dans ce rapport est de déterminer les variables significatives dans le choix d'un assuré de renouveler ou non sa police d'assurance automobile. La variable réponse qui détermine ce choix est appelée `lapse`. Il s'agit d'une variable binaire où la valeur `0` correspond au renouvellement de la police par l'assuré et où la valeur `1` correspond à l'assuré qui ne renouvelle pas sa police. Les données qui ont servi à la réalisation de cette analyse sont celles contenues dans le jeu de données `eurdirectlapse` du paquetage `CASdatasets` de `R` (C. Dutang and A. Charpentier (2024)). Lors de l'analyse exploratoire expliquée dans le rapport *Analyse des facteurs influençant le renouvellement d'une assurance automobile* (Coupal et al., 2025), quelques changements ont été apportés au jeu de données. En effet, des variables indicatrices ont été créées à partir des variables explicatives catégorielles. Certaines ont été regroupées afin de diminuer le nombre de catégories. De plus, des variables de la variation entre les différents types de primes ont été ajoutées afin de mieux observer le lien entre le changement de la prime et la décision de renouvellement des assurés. Entre autres, il est question de la variation entre la prime du marché et celle offerte au renouvellement ainsi que de la variation entre la dernière prime payée et celle offerte au renouvellement. Pour atteindre le but, plusieurs modèles d'apprentissage supervisé seront testés afin de déterminer la meilleure approche.

Modèle de base

Méthodologie

Le jeu de données a été séparé en deux groupes. Les observations d'entrainement, soit celles qui permettent de produire les modèles, correspondent à 80 % du jeu de données initial. Les observations de test, soit le reste, correspondent à celles pour tester l'efficacité des modèles. L'échantillonnage a été fait de manière stratifiée puisque les données sont déséquilibrées. En effet, l'échantillon d'entrainement est constitué de la même proportion de la variable réponse avec une valeur de `1` que le jeu de données initial. La vérification que toutes les catégories des variables explicatives étaient bien représentées a été faite afin de conclure que l'échantillon d'entrainement était représentatif de la base de données.

La validation croisée a été effectuée pour trouver plusieurs hyperparamètres optimaux puisque c'est la méthode à privilégier en présence de données déséquilibrées. En effet, cela permet de réutiliser l'entièreté des données d'entrainement. Le nombre de plis a été choisi en fonction de la puissance requise, donc cinq plis semblaient raisonnables. La validation croisée a été effectuée avec la métrique ROC étant donné qu'elle tente d'avoir le meilleur taux de vrais positifs et de vrais négatifs. Même si les données sont déséquilibrées, la métrique ROC est adéquate étant donné qu'il y aura plus de points aux extrémités du graphique de la courbe ROC, mais les seuils testés plus au centre seront tout de même représentatifs. Un compromis a été recherché entre la sensibilité et la spécificité. Le taux de vrais positifs, soit la sensibilité, est plus intéressant dans le contexte du problème d'intérêt étant donné qu'il est important de savoir pourquoi les assurés quittent la compagnie et que cette catégorie est moins grande. C'est donc ce taux qui a été maximisé dans le compromis de la sensibilité et de la spécificité. La combinaison est différente pour chacun des modèles, mais elle est toujours trouvée en gardant la même logique soit de viser un minimum de 75 % pour la sensibilité lorsque possible. Par contre, il ne faut pas choisir un trop haut seuil au détriment de la spécificité. Puisque plusieurs seuils sont disponibles pour certains modèles, la matrice de confusion des données d'entrainement a été observée afin de choisir le seuil optimal. Le compromis déterminé pour chaque modèle est

indiqué sur les graphiques des courbes ROC où le seuil associé est présenté en rouge.

	Référence	
Prévu	0	1
0	A	B
1	C	D

Équation 1: Matrice de confusion.

Tous les modèles prévoient la probabilité pour chacune des observations de prendre la valeur `1` pour la variable réponse `lapse`. Les modèles ne prévoient pas directement les classes puisque les données sont déséquilibrées.

Certains modèles nécessitent que les données soient standardisées. Dans chaque section des modèles, il sera mentionné s'il était nécessaire de le faire. Cependant, les variables indicatrices n'ont jamais été mises à l'échelle, car elles sont considérées l'étant déjà. En effet, elles peuvent seulement prendre la valeur de `0` ou de `1`, donc elles sont déjà sur l'échelle voulue.

Modèle linéaire généralisé

Le premier modèle réalisé est un modèle linéaire généralisé. La distribution choisie est celle binomiale avec le lien logistique, car la variable réponse est binaire. Le modèle a d'abord été ajusté sur les données mises à l'échelle pour, ensuite, être utilisé pour sélectionner les variables explicatives à conserver. Pour ce faire, la méthode pas à pas *stepwise* a été utilisée. Cette méthode permet de conserver seulement les variables explicatives significatives dans le modèle. Dans la *Table 1*, il est possible d'observer les valeurs des coefficients du modèle linéaire généralisé pour les variables explicatives conservées. Une incohérence du modèle est que toutes les catégories de la variable de la puissance du véhicule ne sont pas présentes. En effet, l'une d'elle n'a pas été sélectionnée par la méthode *stepwise*.

Table 1: Coefficients du modèle GLM.

	Coefficient
Prédicteur de base	-2.000
Diminution du bonus-malus	0.515
Âge du vehicule	-0.074
Âge de la police	-0.201
Prime du marché vs offerte	0.126
Femme	-0.163
Âge de l'assuré	-0.113
Âge du vehicule à l'achat	-0.099
L'assuré est le seul conducteur	-0.148
Moteur de 125-300kW	-0.204
Emploi médical	-0.101
Moteur de 25-50kW	-0.100
Rabais	0.093
Prime offerte vs dernière prime	-0.106
Augmentation du bonus-malus	-0.518

Si toutes les autres variables sont égales par ailleurs, une augmentation d'une unité de la variable explicative générera une augmentation égale à la valeur du coefficient dans le log-rapport de la probabilité soit $\frac{\text{prob}}{1-\text{prob}}$. Par exemple, pour la variable de la diminution du bonus-malus, lorsqu'elle prend la valeur de `1`, le log-rapport de la probabilité augmente de 0.515.

Ensuite, les prévisions de la probabilité que la variable réponse soit `1` ont été calculées. Il a fallu trouver le seuil approprié pour convertir ces probabilités en valeur binaire. Les probabilités plus grandes que le seuil seront des `1`, alors que les plus petites seront des `0`. Pour ce faire, la métrique ROC a été utilisée. Pour avoir une sensibilité de 75 % et une spécificité de 39 %, le seuil choisi est 0.1072261. La *Figure 1* illustre la courbe ROC utilisée pour déterminer le seuil. Puisque l'aire sous la courbe est petite, il est probable que le modèle n'ait pas appris adéquatement des données d'entrainement.

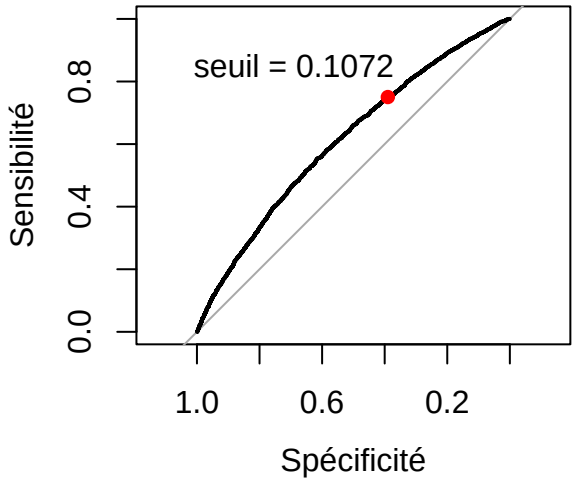

Figure 1: Courbe ROC du GLM sur les données d'entrainement.

Ajustement des modèles

Afin de pousser l'analyse plus loin que le modèle de base, six autres modèles ont été testés.

Modèle linéaire généralisé avec une régularisation

Pour ce modèle linéaire généralisé, la régularisation choisie est celle Lasso groupé, car le jeu de données utilisé contient des variables catégorielles à plusieurs niveaux. De plus, cette régularisation permet d'éliminer certaines variables explicatives parce que leur coefficient sera estimé à `0`. Elle permet donc de faire une sélection des variables explicatives à conserver dans le modèle. De ce fait, le modèle rejettera ou acceptera toutes les variables explicatives du même type. Les données ont été standardisées. La fonction de perte choisie est logistique, car le but du modèle est d'effectuer une classification avec la variable réponse binaire. L'hyperparamètre λ a été déterminé à l'aide de la validation croisée. Sa valeur est 2.46×10^{-4}. Deux variables n'ont pas été sélectionnées par le modèle, soit la dernière prime offerte et celle du marché, donc leur coefficient respectif est nul.

Le modèle créé détermine la probabilité que la variable `lapse` ait une valeur de `1` soit que l'assuré ne renouvelle pas sa police. Par contre, avant d'obtenir la probabilité, différentes étapes sont effectuées. En effet, le modèle renvoie, tout d'abord, les prévisions linéaires. De ce fait, il faut convertir ces valeurs afin de retrouver les probabilités. Le lien suivant est utilisé :

$$\text{Prob} = \frac{e^{\text{prev_lin}}}{1 + e^{\text{prev_lin}}} \text{ , où prev_lin : prévision linéaire.}$$

Équation 2: Calcul des prévisions du modèle de régularisation Lasso.

Ensuite, il est possible de conclure la classe des observations grâce au seuil. Un tableau des différents seuils selon les combinaisons de spécificité et de sensibilité a été analysé. Puisqu'il est très similaire à celui du modèle linéaire généralisé, le choix final s'est arrêté sur 0.107591 soit celui correspondant à une sensibilité de 75 % et à une spécificité de 38.5 %. La *Figure 2* permet d'observer la courbe ROC utilisée pour déterminer le seuil. Cette courbe permet de supposer que le modèle linéaire généralisé avec la régularisation Lasso n'a peut-être pas appris adéquatement des données d'entrainement. En effet, l'aire sous la courbe est petite.

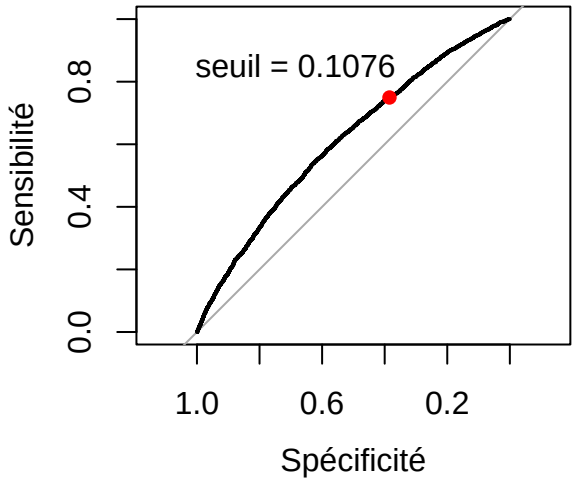

Figure 2: Courbe ROC du GLM avec la régularisation Lasso sur les données d'entrainement.

Modèle des *k* plus proches voisins

Le prochain modèle est basé sur la méthode des k plus proches voisins. Ce modèle permet de prévoir des résultats en faisant la moyenne des valeurs des k observations les plus rapprochées de celle qui veut être prévue. Les données ont été standardisées pour faire les prévisions. Il y a un hyperparamètre à déterminer pour ce modèle, soit le nombre de k voisins de chaque point qui minimisera la courbe ROC, avec la validation croisée. L'intervalle de 1 à 10 a été testé lors de la validation croisée, et le choix optimal est 8. Étant donné que ce n'est pas une valeur à l'extrémité de l'intervalle, il a été déterminé que cette valeur est satisfaisante.

Le choix final du seuil pour convertir les probabilités en variable binaire s'est arrêté sur 0.0625 parce que la sensibilité est de 70.3 % et que la spécificité est de 36.6 %. Dans ce cas, il était impossible d'atteindre le minimum de 75 % recherché pour la sensibilité à moins d'avoir une spécificité nulle. La *Figure 3* permet d'observer la courbe ROC de ce modèle. L'aire sous la courbe est pratiquement nulle, ce qui laisse penser que ce modèle des k plus proches voisins n'est pas optimal pour modéliser les données d'entrainement.

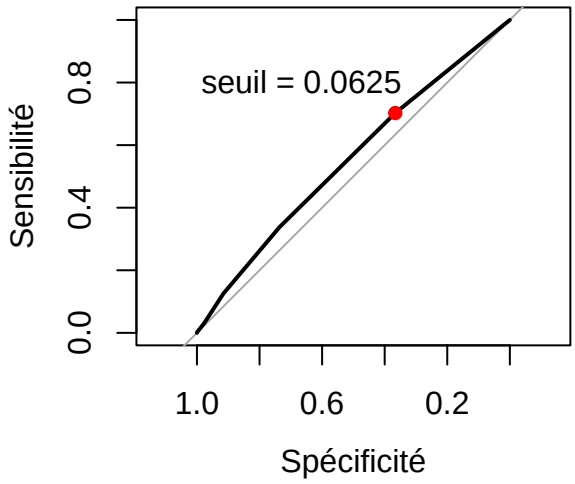

Figure 3: Courbe ROC des k plus proches voisins sur les données d'entrainement.

Arbre de décision

Le modèle de l'arbre de décision est basé sur l'algorithme CART qui permet de créer des règles de décision en se basant sur les variables explicatives, non standardisées, et de les raffiner progressivement à l'aide de décisions hiérarchiques. Ainsi, les règles de décision permettent de discriminer les assurés qui renouvellent leur police d'assurance de ceux qui ne la renouvellent pas. Cet algorithme est disponible dans le paquetage `rpart`.

La première étape est de déterminer la valeur de l'hyperparamètre *cp*. Ce paramètre permet de contrôler la croissance de l'arbre, donc sa complexité. La validation croisée a été utilisée afin de trouver le paramètre optimal soit 4.23×10^{-4}. Pour effectuer la validation croisée, le paramètre `tuneLength` de la fonction `train` a été fixé à 10, ce qui signifie que 10 valeurs du paramètre *cp* ont été testées. La neuvième valeur est considérée comme optimale. Le paramètre `tuneLength` d'une valeur de 15 a été testé afin de vérifier si la même valeur ressortait. En effet, la valeur du paramètre initialement obtenue est bel et bien optimale.

Afin d'inclure la valeur du paramètre de complexité dans la construction de l'arbre, un arbre surajusté a d'abord été construit avec les hyperparamètres fixés. Le paramètre de complexité est nul, et le nombre minimal d'observations par feuille ainsi que le nombre minimal d'observations par nœud sont de 1. Il est surajusté aux données d'entrainement puisqu'il n'est aucunement pénalisé pour sa complexité en plus de n'avoir aucune autre restriction. Par la suite, en utilisant le paramètre de complexité optimal trouvé précédemment, l'arbre surajusté a été élagué pour uniquement conserver les divisions de l'arbre pertinentes. Étant donné que la valeur du paramètre de complexité est très près de 0, l'arbre obtenu avec le modèle est très gros comme il est possible de l'observer sur la *Figure 4*. De ce fait, ce modèle complexe a une grande variance et un petit biais.

L'arbre élagué peut ensuite être utilisé afin de prévoir des valeurs binaires de la variable réponse soit pour le renouvellement ou non de l'assurance. Pour l'arbre, le seuil déterminé est 0.1037 soit celui correspondant à une sensibilité de 53 % et à une spécificité de 65 %. Encore une fois, il n'était pas possible de sélectionner une valeur de sensibilité supérieure à 75% sans que la mesure de spécificité ne soit trop près de 0. La *Figure 5* montre la courbe ROC de l'arbre.

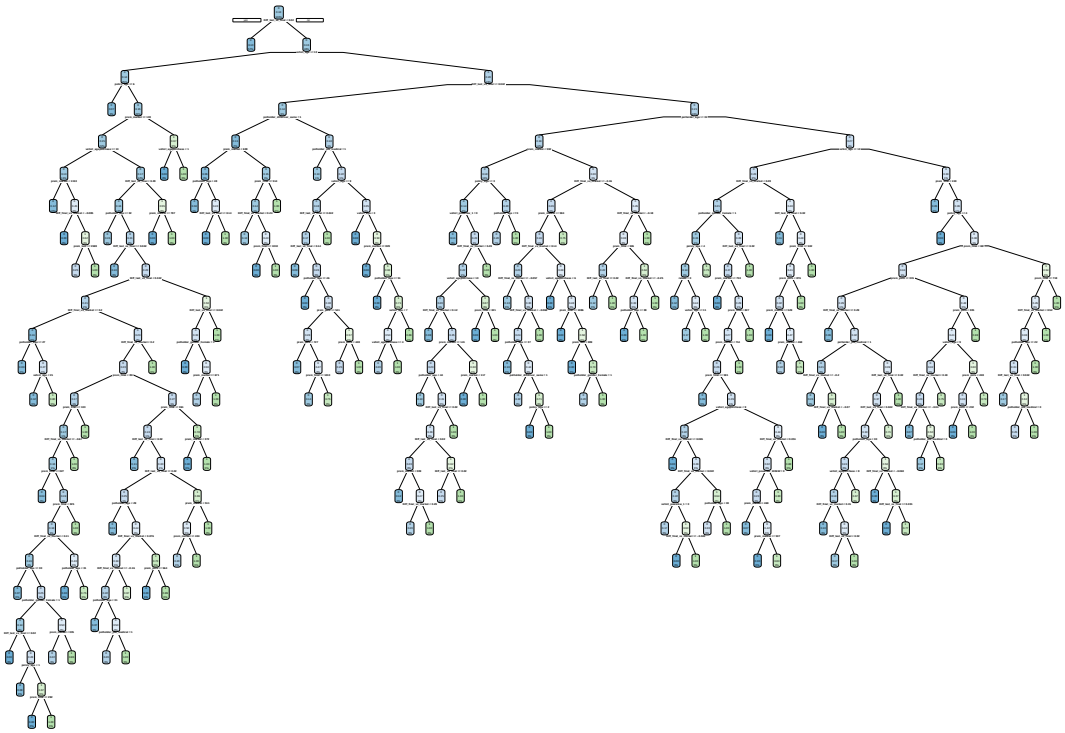

Figure 4: Arbre élagué sur les données d'entrainement.

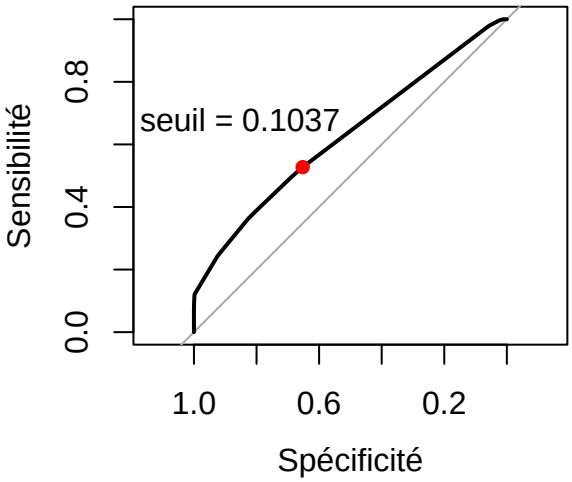

Figure 5: Courbe ROC de l'arbre sur les données d'entrainement.

Ensemble d'arbres de décision agrégés par *bagging*

Le prochain modèle est un ensemble d'arbres de décision agrégés par *bagging*. Ce modèle consiste à générer plusieurs arbres de décision afin que la prévision soit la moyenne des prévisions de chacun des arbres. Grâce à cette méthode, la variance des prévisions sera moindre, donc elles seront meilleures. Chaque arbre sera formé à l'aide du même nombre d'observations que dans les données d'entrainement, mais l'échantillonnage sera fait avec remise. De ce fait, les observations ne se retrouveront pas toutes dans tous les arbres. Tout d'abord, le nombre d'arbres optimal à faire a été déterminé à l'aide de l'erreur *out-of-bag* (OOB). Puisque le nombre d'arbres est assez grand, l'erreur OOB est équivalente à celle de la validation croisée. L'erreur *out-of-bag* est calculée à partir des observations non utilisées dans chacun des arbres. Le premier essai était avec 150 arbres et minimalement deux observations par feuille. Comme il est possible de l'observer dans la *Figure 6*, l'erreur semble être stabilisée à partir de 50 arbres. De ce fait, l'hyperparamètre du nombre d'arbres dans le modèle de *bagging* a été fixé à 100 arbres.

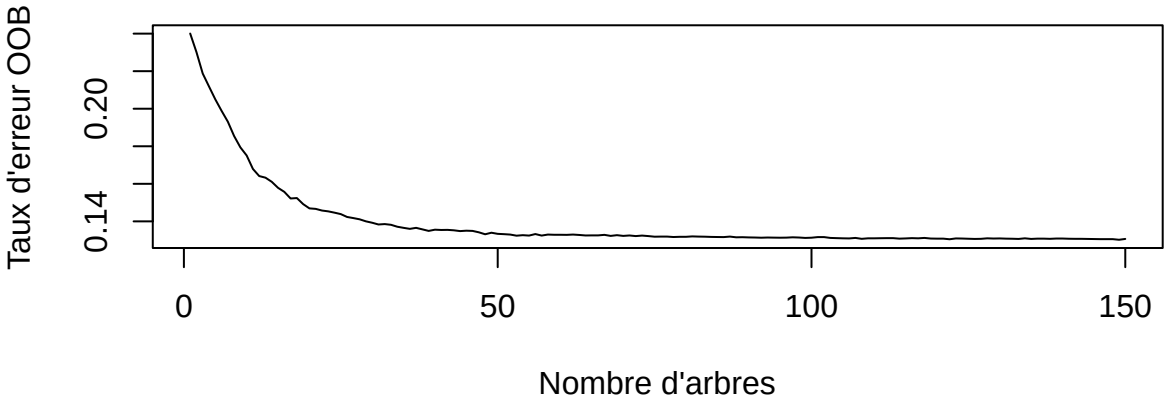

Figure 6: Taux d'erreur OOB par nombre d'arbres.

Le deuxième hyperparamètre à choisir est le nombre d'observations minimal par feuille des arbres. Il a été fixé à 4 grâce à un échantillon de validation contenant 20 % des données d'entrainement. Toutes les valeurs dans un intervalle de 1 et 15 ont été essayées. Puisque la valeur optimale de 4 n'est pas à l'extrémité de l'intervalle des valeurs testées, elle a été acceptée.

Ensuite, le modèle de *bagging* a pu être complété avec les deux hyperparamètres optimaux. Comme pour les autres modèles, un seuil a dû être déterminé afin de transformer les probabilités obtenues en valeur binaire. Ce seuil est de 0.39 soit celui qui permet d'avoir une spécificité de 99.6 % et une sensibilité de 99.99 %. Ce seuil est le seul où les deux métriques ne sont pas de 100 %. Par contre, comme il est possible de le voir sur la *Figure 7*, le modèle est surentrainé sur les données d'entrainement. Il est donc probable que, lorsque de nouvelles observations seront utilisées, le modèle ne fera pas des prévisions autant adéquates.

Forêt aléatoire

Le prochain modèle est une forêt aléatoire. La méthode de ce modèle ressemble beaucoup à celle du modèle précédent, mais avec deux techniques ajoutées pour décorréler les arbres afin de diminuer davantage la variance. Premièrement, chacun des arbres n'auront pas le même nombre d'observations que le jeu de données initial d'entrainement. En effet, ils auront plutôt seulement que 75 % des données disponibles ce qui permettra d'avoir des échantillons plus différents. Ce choix de valeur a été fait dans le but de conserver une assez grande partie des données afin d'avoir une plus grande

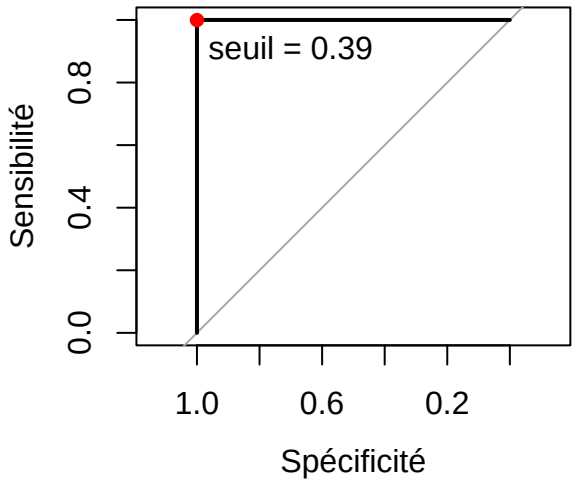

Figure 7: Courbe ROC du bagging sur les données d'entrainement.

probabilité qu'il y ait des observations avec la variable réponse d'une valeur de `1`. L'argument à modifier est `sampsize`. Deuxièmement, la forêt aléatoire permet, à chaque séparation des arbres, de n'avoir qu'un nombre déterminé de prédicteurs disponibles. C'est l'argument `mtry` qui doit être ajusté. Comme pour le modèle de *bagging*, il a fallu déterminer la valeur de l'hyperparamètre du nombre d'arbres optimal. La même technique a été utilisée soit de tester en premier le modèle avec 150 arbres et minimalement deux observations dans chaque feuille pour déterminer à quelle valeur l'erreur *out-of-bag* se stabilise.

Pour ce modèle construit avant la détermination des hyperparamètres, le nombre de prédicteurs disponibles par séparation est de 4, soit la valeur plancher de la racine carrée de 19. En classification, le nombre de base est la racine carrée du nombre de variables explicatives. Un graphique similaire à la *Figure 6* a été analysé pour en tirer la même conclusion soit celle de choisir 100 arbres.

Ensuite, la valeur optimale des deux autres hyperparamètres a été déterminée à l'aide d'une seule boucle. En effet, l'objectif a été de déterminer la paire de paramètres du nombre de prédicteurs et du nombre d'observations minimal par feuille la plus optimale. De ce fait, chaque couple a été essayé avec un échantillon de validation de 20 % des données d'entrainement. Les valeurs retenues sont de 3 prédicteurs par séparation et de 13 observations minimalement par feuille. L'une des limitations de ce modèle est que l'hyperparamètre du pourcentage de données par arbre n'a pas été optimisé.

Après cela, le modèle est prêt à prévoir les probabilités que la variable réponse ait une valeur de `1`. Ensuite, le seuil pour convertir ces probabilités en valeur binaire a été déterminé à l'aide de la courbe ROC. Il est de 0.145 soit celui avec une sensibilité de 98 % et une spécificité de 95 %. Comme il est possible de le voir sur la *Figure 8*, ce modèle a aussi causé du surapprentissage sur les données d'entrainement.

Modèle de gradient *boosting*

Le dernier modèle créé en est un basé sur l'algorithme de *boosting* de gradient XGBoost. L'objectif du *boosting* est de combiner plusieurs modèles faibles en un modèle prédictif puissant par une méthode itérative. À chaque itération, l'arbre produit tente d'améliorer les prévisions les moins bien faites du précédent. Chaque arbre aura une contribution inversement proportionnelle à son taux d'erreur. La fonction de perte utilisée est logistique puisque le modèle effectue la classification

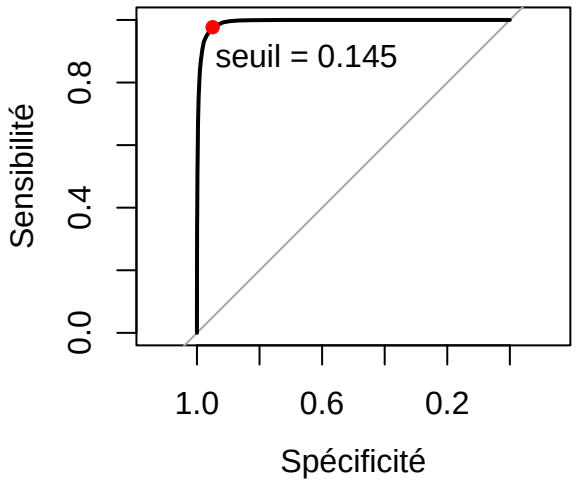

Figure 8: Courbe ROC de la forêt sur les données d'entrainement.

d'une variable binaire.

Il y a deux hyperparamètres à optimiser selon la métrique ROC soit le nombre d'itérations et la taille maximale de l'arbre. La méthode utilisée est la validation croisée. Premièrement, des valeurs entre 100 et 1000, par bonds de 100, ont été testées pour déterminer le nombre d'itérations optimal. La meilleure valeur est 700. Deuxièmement, les tailles maximales des arbres de 2, 3, 5 et 7 séparations ont été testées pour finalement déterminer que 2 est la valeur optimale. Ce paramètre représente le niveau d'interactions entre les variables explicatives. Comme il est possible de l'observer dans la *Figure 9*, ce sont ces valeurs qui maximisent la métrique ROC. La valeur minimale testée est 2 pour la taille maximale des arbres afin d'avoir un peu d'interactions entre les variables explicatives. Lorsque la valeur 1 a été testée, celle-ci a été sélectionnée, mais cela correspond à un modèle sans interaction. Cela ne semblait pas approprié puisqu'il y aurait autant d'interactions que le modèle linéaire généralisé. La valeur 2 a donc été choisie.

Certains hyperparamètres ont été fixés. En effet, le paramètre de régularisation, le pourcentage de sous-échantillonnage, le nombre minimal d'observations par feuille, le ratio de sous-échantillonage des colonnes et la réduction minimale dans la fonction de perte pour procéder à une autre séparation ont été fixés à des valeurs respectives de : 0.01, 75 %, 5, 1 et 0.3. Ces valeurs sont celles par défaut, sauf pour le pourcentage de sous-échantillonnage qui a été fixé pour les mêmes raisons que le paramètre de la forêt aléatoire.

Le modèle a ensuite servi à déterminer la probabilité qu'une observation ait une valeur de `1` pour la variable réponse. La métrique ROC a été utilisée pour déterminer le seuil. Il est de 0.1137 soit celui correspondant à une sensibilité de 75 % et à une spécificité de 44 %. Avec la matrice de confusion sur les données d'entrainement, c'était le meilleur compromis. Comme il est possible de l'observer sur la *Figure 10*, le modèle n'a pas bien été entrainé sur les données.

Comparaison des modèles

Pour pouvoir comparer les modèles, il est important de les essayer sur les données de tests. Ceci permet d'observer comment les modèles performent réellement sur différentes observations et non seulement sur celles qui ont été utilisées pour l'ajustement. Il faut ensuite utiliser différentes

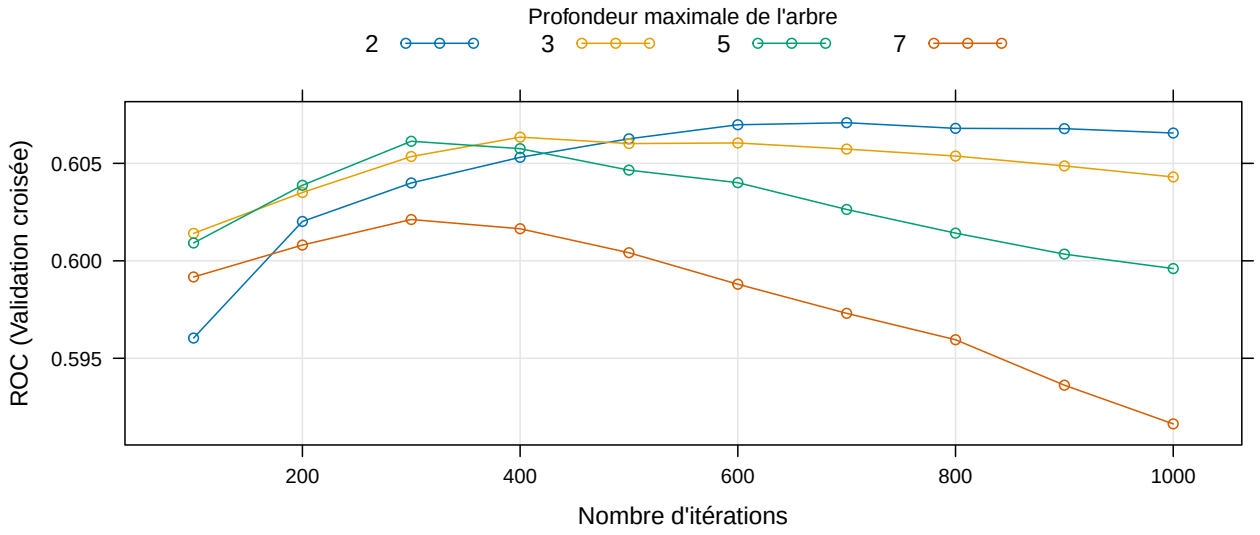

Figure 9: Validation croisée pour le choix des hyperparamètres utilisés dans le modèle de boosting.

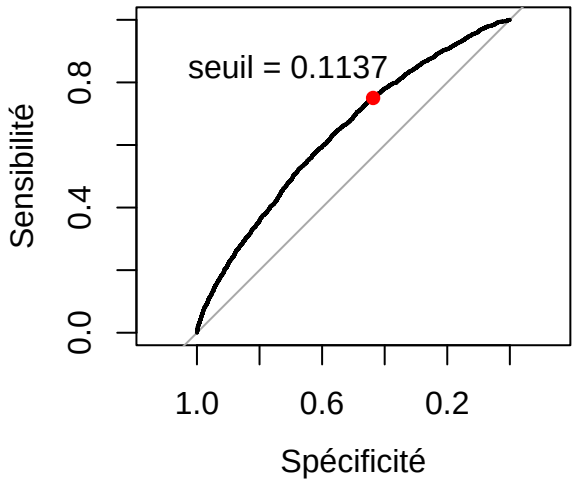

Figure 10: Courbe ROC du boosting sur les données d'entrainement.

métriques sur les résultats des modèles testés avec les données de test. Les métriques utilisées pour la comparaison sont : le graphique de la courbe ROC, la valeur de son aire sous la courbe (AUC), la F-mesure, la sensibilité et le temps d'entrainement.

Courbe ROC et aire sous la courbe

La courbe ROC permet de visualiser la performance du modèle pour différents seuils. Le meilleur point d'une courbe ROC est lorsque la sensibilité et la spécificité sont les deux maximisées, donc le coin supérieur gauche. Une courbe qui est tracée au-dessus de la ligne qui coupe le graphique à 45 degrés est considérée comme meilleure que le hasard. L'aire sous la courbe ROC (AUC) est une façon plus numérique de comparer les modèles. Une AUC de 0.5 représente un modèle qui n'est pas mieux que le hasard. Alors, plus l'AUC est élevée, plus le modèle est performant.

Les métriques précédentes sont utiles puisqu'il n'est pas nécessaire de préalablement convertir les probabilités prévues en variable binaire pour les utiliser. Ceci permet de comparer les modèles avant d'avoir fait le choix du seuil. Ceci est un avantage étant donné que le choix du seuil, bien qu'il soit basé sur des métriques, reste avec une part de subjectivité.

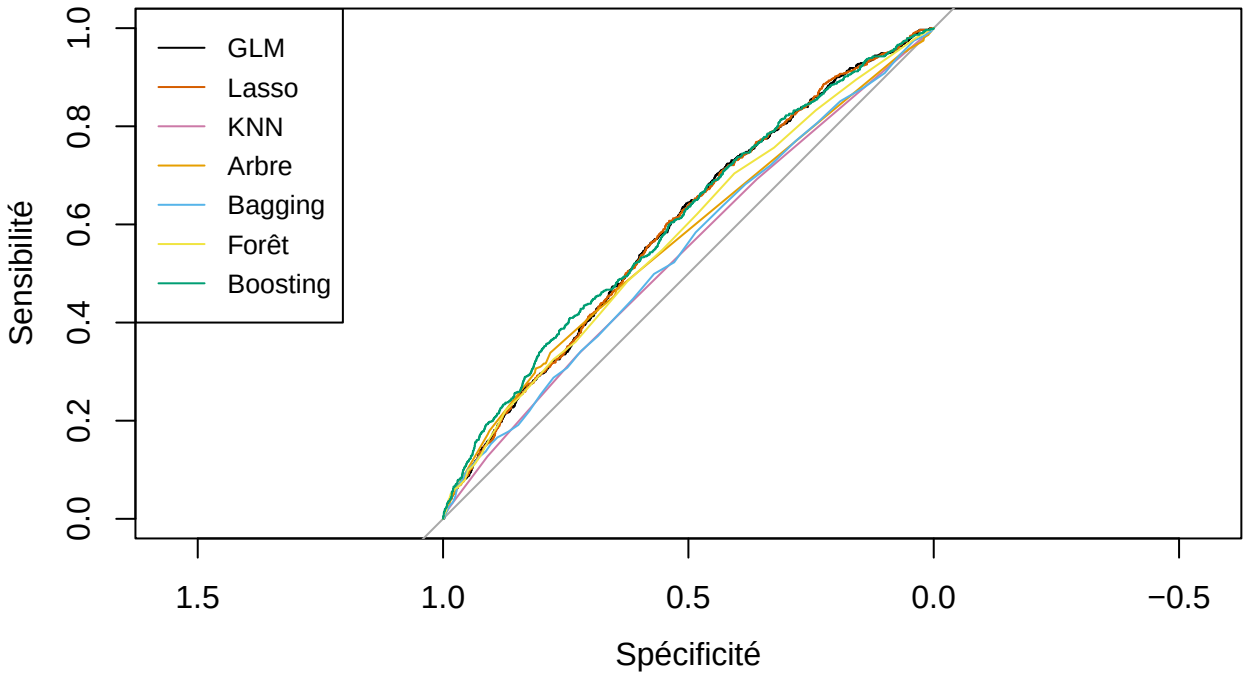

Figure 11: Courbes ROC des modèles sur les données de test.

Comme il est possible de l'observer sur la *Figure 11*, les courbes ROC faites sur les données de test diffèrent de celles faites sur les données d'entrainement étant donné que certains modèles sont surentrainés. Bien que les valeurs de l'aire sous la courbe ROC ne soient pas très élevées, comme illustrées dans la *Figure 12*, celle du modèle de *boosting* est la plus grande. En effet, le modèle est meilleur que le hasard même s'il est encore très loin de la valeur optimale de 1. Les modèles en deuxième position sont ceux linéaires généralisés (GLM et GLM avec régularisation Lasso). Par rapport à l'intervalle des valeurs de l'AUC, la différence entre les trois meilleurs modèles est grande mais, sans égard à l'échelle, la différence est très petite.

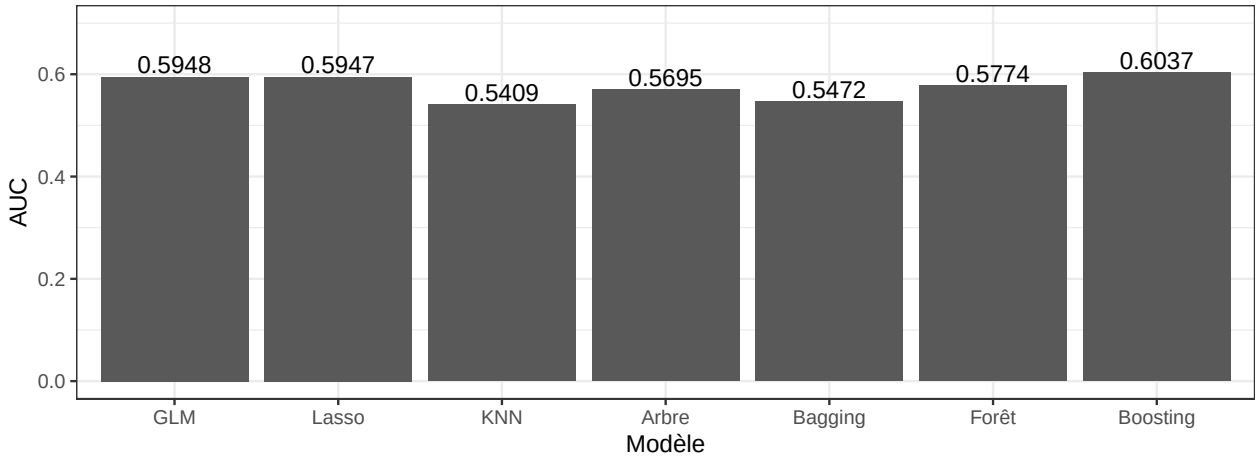

Figure 12: Aire sous la courbe ROC des modèles sur les données de test.

F-mesure

La F-mesure nécessite des prévisions converties en variables binaires. Cette métrique s'avère très utile pour les données déséquilibrées puisqu'elle permet d'utiliser simultanément la précision et la sensibilité. Ces métriques sont calculées à partir de la matrice de confusion (*Équation 1*). En effet, la sensibilité permet de donner un poids aux valeurs de `1` bien prévues en plus de ne pas exagérer le nombre de `1` prévus. Une valeur de 0 pour la F-mesure n'est pas souhaité, alors qu'une valeur de 1 est optimale. Elle se calcule comme suit :

$$F_{\text{mesure}} = \frac{2 \times \text{sensibilité} \times \text{précision}}{\text{sensibilité} + \text{précision}} \text{ , où la sensibilité = A/(A+C) et la précision = D/(B+D).}$$

Équation 3: F-mesure.

Comme illustré dans la *Figure 13*, les F-mesures les plus élevées sont celles des modèles linéaires généralisés et du modèle de *boosting*. Encore une fois, les valeurs de la métrique sont sensiblement pareilles d'un modèle à l'autre comme il est possible de l'observer en regardant l'échelle de l'axe des ordonnées de la *Figure 13*.

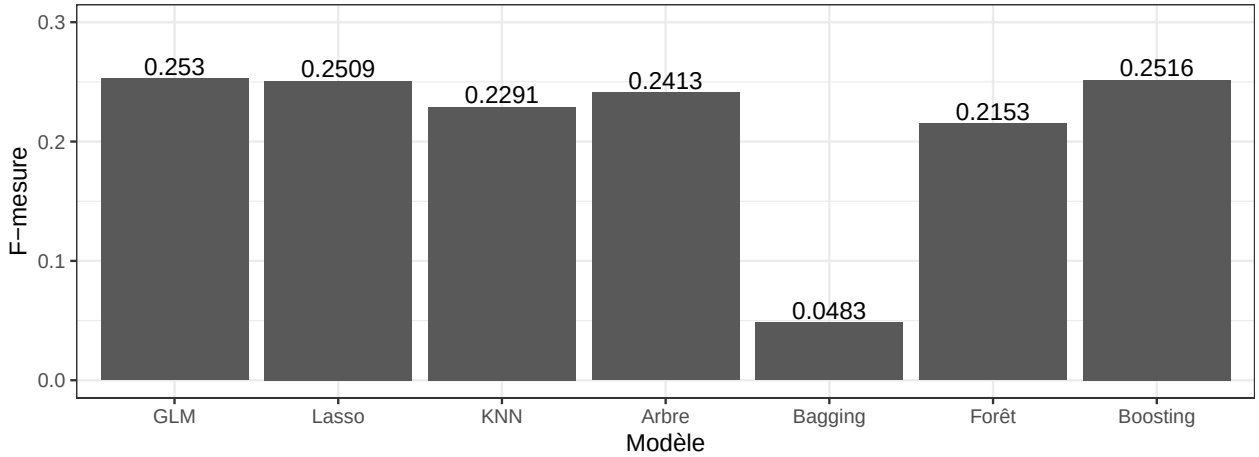

Figure 13: F-mesure des modèles sur les données de test.

Sensibilité

La sensibilité représente le nombre de positifs qui ont bien été prévus divisé par le nombre de positifs dans les observations. Elle indique donc le taux de vrais positifs. Ceci est intéressant pour un cas déséquilibré parce qu'il est important de bien prévoir les données positives étant donné qu'elles sont moindres. De plus, ce sont les plus importantes dans le contexte du problème d'intérêt étant donné qu'un assureur doit bien prévoir le nombre de personnes qui quitteront sa compagnie.

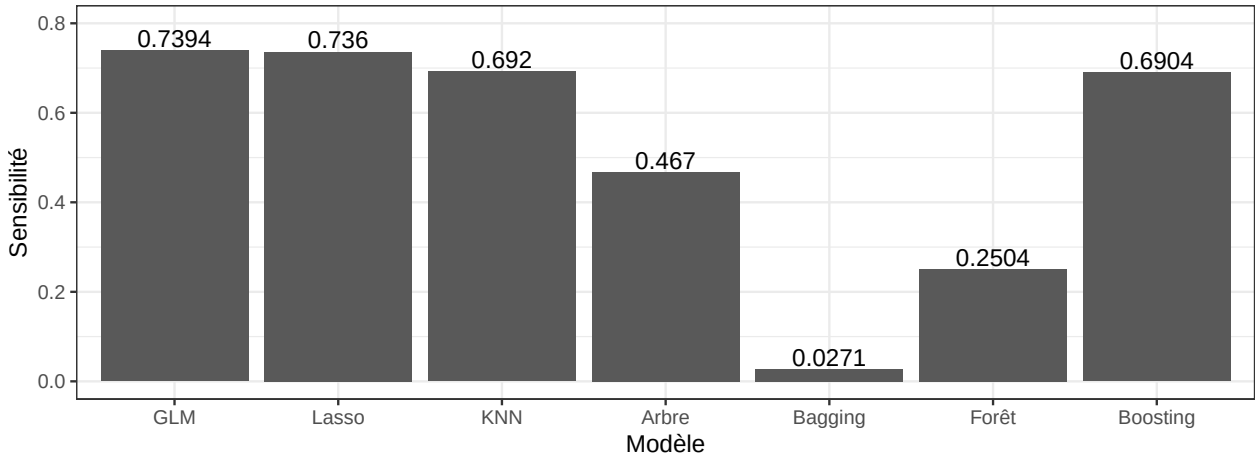

Figure 14: Sensibilité des modèles sur les données de test.

Comme illustré dans la *Figure 14*, la sensibilité la plus élevée est celle du modèle linéaire généralisé suivie par celle du modèle linéaire généralisé avec régularisation Lasso groupé. Le modèle de *boosting*, qui était très bon jusqu'à présent, n'est pas optimal pour cette métrique. Il est quatrième devancé par le modèle des k plus proches voisins.

Temps d'entrainement

Finalement, une métrique qui peut faire une grande différence lorsqu'il faut choisir entre plusieurs bons modèles est le temps d'entrainement. Celui-ci correspond au temps nécessaire pour l'optimisation des hyperparamètres par exemple. Certains modèles peuvent prendre beaucoup plus de temps que d'autres. Parfois, l'attente vaut la peine, mais si deux modèles performent bien, il est préférable de choisir le plus rapide. Les temps de chargement des modèles ont été mesurés par un MacBook Air 2022 (Puce Apple M2 avec un processeur à 8 cœurs).

Table 2: Temps d'exécution des modèles.

Modèle	Temps
GLM	8.26 sec.
Lasso	10.04 sec.
KNN	43.48 sec.
Arbre	2.51 sec.
Bagging	46.64 sec.
Forêt	9.98 min.
Boosting	6.13 min.

Comme il est possible de l'observer dans la *Table 2*, le modèle de *boosting* en est un avec un temps d'entrainement élevé, alors que les modèles généralisés sont ceux qui en nécessitent le moins.

Choix des meilleurs modèles

Avec ces différentes métriques, il est possible de choisir les modèles les plus performants pour résoudre le problème d'intérêt.

Pour la métrique de l'aire sous la courbe ROC, le modèle de *boosting* est celui avec la plus haute valeur. Il est suivi de près par les deux modèles linéaires généralisés. Pour ce qui est de la F-mesure des trois modèles nommés précédemment, elles ont pratiquement toutes la même valeur. La sensibilité est où un écart marqué se trace. En effet, les modèles linéaires ont pratiquement la même mesure, mais le modèle de *boosting* est loin derrière. Vu l'écart minime entre les métriques de ces trois modèles et leur supériorité comparativement aux autres modèles, le choix s'est arrêté sur le modèle de gradient *boosting* et le modèle linéaire généralisé avec régularisation Lasso. La raison pour laquelle le modèle généralisé avec la régularisation est préférable à celui qui n'en utilise pas est que, comme mentionné dans la sous-section *Modèle linéaire généralisé*, ce dernier ne conserve pas toutes les variables catégorielles d'un même type. À l'opposé, la régularisation Lasso groupé permet d'éliminer cette incohérence. De plus, les métriques de ces deux modèles sont semblables voire identiques.

Interprétation des deux meilleurs modèles

Les deux modèles sélectionnés sont le modèle de gradient *boosting* et le modèle linéaire généralisé avec régularisation Lasso. Ces modèles ont des interactions entre les variables explicatives très faibles. En effet, un modèle linéaire n'a pas d'interaction, et le modèle de *boosting* a sélectionné l'hyperparamètre d'interactions le plus faible. De ce fait, il est possible de s'attendre à ce que peu de variables soient corrélées les unes avec les autres. Seulement les interactions entre les variables explicatives les plus intéressantes seront présentées.

Modèle de gradient *boosting*

La *Figure 15* illustre l'importance des variables explicatives du modèle de *boosting*.

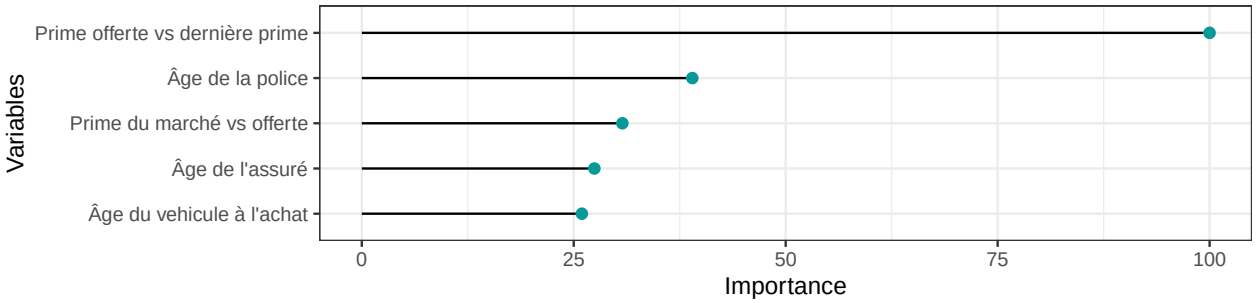

Figure 15: Importance des variables explicatives du modèle de boosting.

La variable la plus importante est le ratio de la différence entre la dernière prime payée et celle offerte au renouvellement. La *Figure 16* permet d'observer l'effet de la variable explicative la plus importante sur la variable réponse. Ce graphique de dépendance partielle permet de comprendre l'effet global de la variable explicative la plus significative. Il est possible de voir que, pour une valeur

négative de cette variable, soit une prime offerte plus grande que la dernière payée, la probabilité de rester chez l'assureur augmente. Cela concorde avec les conclusions de l'analyse exploratoire (Coupal, et al., 2025) qui stipulaient que les mauvais risques ont tendance à rester dans la compagnie étant donné qu'ils ne peuvent sûrement pas trouver meilleur ailleurs. Cela confirme le risque d'antisélection de cet assureur. Pour ce qui est de la deuxième variable la plus importante, l'âge de la police, un changement dans celle-ci n'influence pas la valeur de la variable réponse.

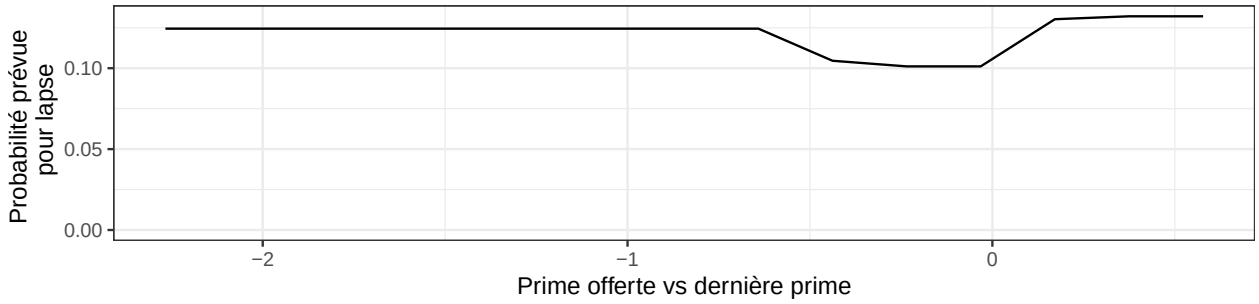

Figure 16: Dépendance partielle de la variable de la différence entre la dernière prime payée et celle offerte au renouvellement dans le modèle de boosting.

Afin de découvrir les interactions entre les variables explicatives importantes et les autres, des graphiques de la statistique H de Friedman sont présentés.

La *Figure 17* illustre les interactions entre les variables explicatives et la variable du ratio de la différence entre la dernière prime payée et celle offerte au renouvellement. Il est possible de constater que cette variable interagit le plus fortement avec la variable de l'âge de l'assuré.

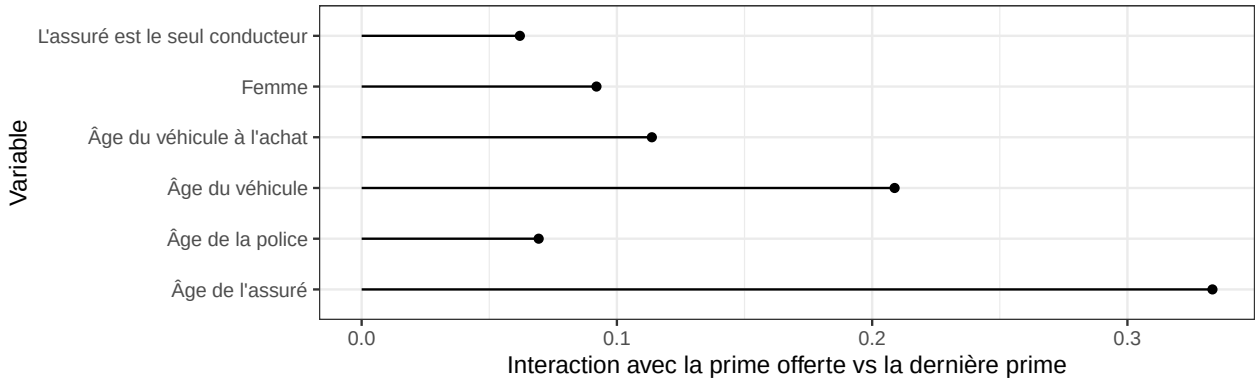

Figure 17: Statistique H de Friedman de la variable de la différence entre la dernière prime payée et celle offerte au renouvellement dans le boosting.

Avantages et désavantages du modèle

Les avantages du modèle de gradient *boosting* sont que c'est un modèle qui est généralement très efficace puisqu'il utilise un apprentissage séquentiel afin de s'améliorer lors des prochaines itérations. Cependant, dû à cette méthodologie, ce modèle peut être très lourd et devenir très long à entrainer. Il est également moins bien interprétable que d'autres modèles comme le GLM ou les arbres et, dans ce cas-ci, il ne procure pas une AUC beaucoup plus élevée que le GLM.

Modèle avec régularisation Lasso

Les variables explicatives les plus importantes dans le modèle linéaire généralisé avec régularisation Lasso sont l'augmentation et la diminution du bonus-malus comme illustré dans la *Figure 18*. Ces variables sont celles avec les plus grands coefficients. De plus, l'ordonnée à l'origine du modèle a une grande importance dans le modèle. Elle aura donc un grand poids, elle aussi, dans la modélisation des prévisions.

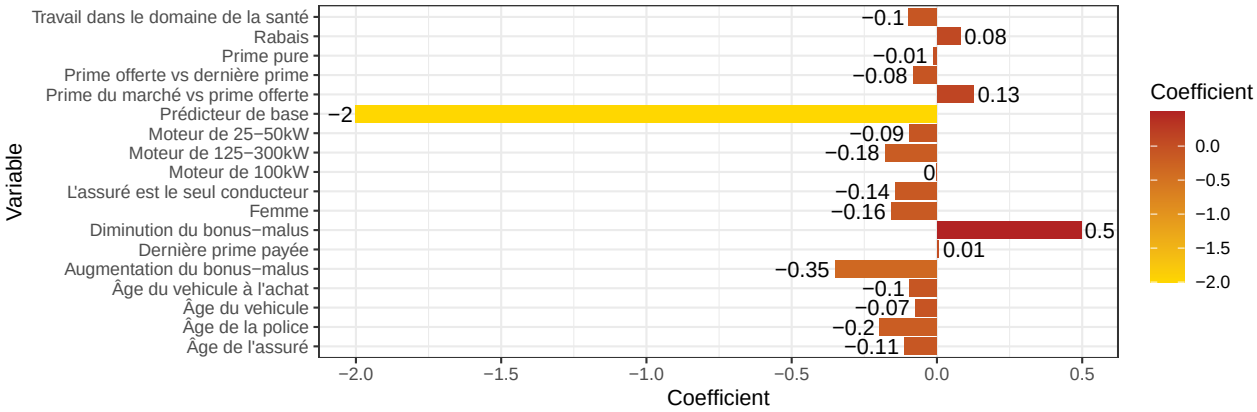

Figure 18: Importance des variables du GLM avec régularisation Lasso.

Puisque le modèle linéaire généralisé avec régularisation n'a pas été entraîné avec `caret`, il est nécessaire de créer une fonction de prévision. Cette dernière servira à créer l'objet `Predictor$new` qui sera utile pour créer les graphiques voulus.

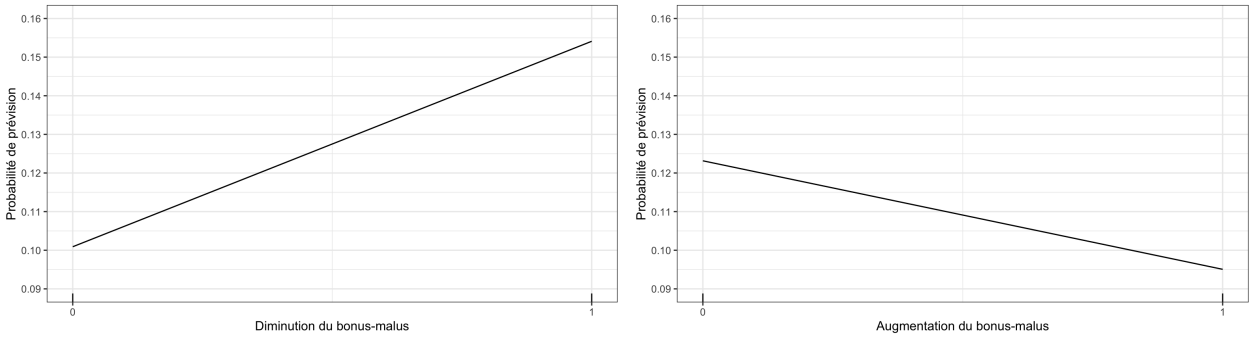

Figure 19 : Dépendance partielle des variables de variation du bonus-malus dans le GLM avec régularisation Lasso.

La *Figure 19* permet d'observer l'effet des variables explicatives les plus importantes du modèle linéaire généralisé avec régularisation sur la variable réponse. Rapidement, il est possible d'observer que leur effet est semblable, mais contraire. Ceci est logique puisque leur coefficient est similaire, mais avec des signes opposés soit 0.4983 pour la diminution du bonus-maluse et -0.3503 pour l'augmentation du bonus-malus. De plus, l'angle de la droite est dû au fait que les deux variables les plus importantes sont des indicatrices. Ainsi, il est nécessaire de seulement s'intéresser aux extrémités de la droite soit lorsque la variable prend la valeur de `1` ou de `0`. Lorsque la variable indicatrice de la diminution du bonus-malus prend la valeur de `1`, la probabilité de ne pas renouveler augmente. C'est l'inverse pour la variable indicatrice de l'augmentation du bonus-malus. Cela est cohérent avec la conclusion que les meilleurs assurés trouvent mieux à d'autres compagnies. Par contre, le poids de la variation dans la probabilité est plus important pour la variable explicative de

la diminution du bonus-malus étant donné que la valeur de son coefficient est plus élevée.

Il n'y a pas d'interactions entre les variables de la variation du bonus-malus et les autres variables explicatives.

Avantages et désavantages du modèle

Le modèle linéaire généralisé avec régularisation est un modèle simple à mettre en œuvre et permet d'être entrainé en très peu de temps. Pour un modèle avec peu d'interactions entre les variables, il permet d'obtenir de bonnes prévisions. En revanche, puisque le prédicteur de base a une grande influence sur les prévisions avec son poids supérieur à ceux des coefficients, les prévisions seront en général toutes près de la moyenne. Pour un modèle comme dans le cas présenté dans ce rapport, malgré le peu d'interactions observées, il semble un peu simple, mais il permet de bien modéliser les observations à prévoir.

Conclusion

L'analyse des sept modèles conçus permet de conclure que l'un des meilleurs modèles pour le jeu de données d'intérêt est le modèle de gradient *boosting*. Cependant, comme expliqué plus haut, la valeur de l'hyperparamètre de la profondeur maximale de l'arbre a été forcée à 2. La validation croisée déterminait une feuille maximum, lorsqu'il lui était possible, mais cela représente autant d'interactions qu'un GLM soit le modèle de base. Bien que les métriques du modèle de *boosting* soient généralement bonnes, celles du modèle linéaire généralisé avec régularisation Lasso le sont aussi. Le temps d'entrainement du modèle de *boosting* et sa complexité ne sont pas justifiés au vu de l'écart minime entre la performance des deux modèles d'apprentissage supervisé. De plus, étant dans un problème où la prévision de la valeur positive de la variable réponse est très importante, la sensibilité doit être prise en compte. Puisque le modèle de *boosting* a une valeur plus faible pour cette métrique, le modèle recommandé pour résoudre le problème d'intérêt serait le modèle généralisé avec régularisation Lasso groupé.

Les données étant déséquilibrées, il est difficile de construire un modèle qui est capable de faire de très bonnes prévisions. De ce fait, il est difficile d'utiliser les modèles créés pour résoudre le problème initial soit de rechercher les variables significatives dans la décision de renouvellement d'une police d'assurance automobile européenne d'un assuré. Ceci est causé par le manque d'interactions entre la variable réponse et les variables explicatives. La seule conclusion qui est toujours possible de soutenir avec l'analyse des modèles est que l'assureur est à risque d'antisélection.

Plus d'informations sur le bonus-malus, comme son fonctionnement précis et la valeur du coefficient, pourraient permettre de faire de meilleures conclusions en lien avec l'historique des sinistres de l'assuré. Puisque le choix de renouvellement est subjectif et que la seule variable qui l'influence directement dans la base de données est la prime offerte, il serait intéressant d'avoir des variables explicatives en lien avec la satisfaction des assurés. Cela constituerait une amélioration étant donné que cela augmenterait les interactions entre les variables explicatives et la variable réponse.

Bibliographie

Brownlee, J. (2020), *How to Calculate Precision, Recall, and F-Measure for Imbalanced Classification*, Récupéré le 23 mars 2025 de https://machinelearningmastery.com/precision-recall-and-f-measure-for-imbalanced-classification/

Coupal, M. et al., (2025), *Analyse des facteurs influençant le renouvellement d'une assurance automobile.*

C. Dutang and A. Charpentier (2024), CASdatasets: European lapse dataset from the direct channel, R package version 1.2-0, https://doi.org/10.57745/P0KHAG

Google Developers (2024). *Classification: ROC et AUC*, Récupéré le 1 avril 2025 de https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc?hl=fr#:~:text=La%20courbe%20ROC%20est%20une,de%20la%20Seconde%20Guerre%20mondiale.